

Rúbrica — Llamada simulada de venta consultiva de IA

Versión 1.0 (borrador) · 5 capas · Escala 0.0–1.0 por criterio

Escenario: Llamada simulada donde un agente IA actúa como cliente/prospecto y presenta objeciones reales. El evaluado (nativo) debe sostener una conversación de alto valor comunicando el impacto comercial, técnico y estratégico de la IA de Nativa.

Productos ancla de esta versión:

- **P1 — Sistema Multiagéntico de Evaluación** (voicebot evaluador + agentes en paralelo por criterio)
- **P2 — Conversational AI Qualitative Surveying** (encuestas cualitativas telefónicas con agente de voz)

Meta de la iniciativa: ≥ 8.5/10 en capacidad y claridad para comunicar el impacto.
Equivalencia: promedio ponderado ≥ 0.85.

Agregación propuesta (ajustable):

Capa	Peso
D1 Técnica	20%
D2 Comercial	20%
D3 Estrategia	25%
D4 Diagnóstico	20%
D5 Consultoría y servicios	15%

Cada bloque D1–D5 es autocontenido: descriptor, anclas de producto, seis niveles de logro y banderas rojas. Cada agente evaluador recibe únicamente su bloque.

D1 — Técnica (20%)

Qué evalúa: Si el evaluado explica con precisión qué es la IA que ofrece Nativa, cómo funciona

y qué capacidades y límites técnicos tiene — incluyendo alucinaciones y seguridad — sin refugiarse en generalidades ni sobreprometer. Incluye KYC: cómo se verifica identidad y cómo el producto cumple, a nivel técnico, con la legislación aplicable.

Anclas de producto (evidencia válida en transcript):

- P1: agente conversacional + sistema multiagéntico donde cada agente especializado califica UN criterio; agentes creados dinámicamente según número de criterios; anclaje en RAG con rúbrica única (control de drift); evaluadores separados del agente conversacional (sin conflicto de objetivos); audit trail por criterio, versión de rúbrica y timestamp.
- P2: agente de voz que llama, adapta preguntas dinámicamente, profundiza por respuesta, genera insight por pregunta y análisis agregado.
- Límites técnicos legítimos: riesgo de alucinación y cómo se mitiga (RAG, reglas aisladas por agente, neutralidad del voicebot, restricción de no dar soluciones), latencia, dependencia de la calidad del input.
- KYC: verificación de identidad en flujos conversacionales y cumplimiento técnico (p. ej. tratamiento de datos personales bajo la legislación aplicable, consentimiento, resguardo de grabaciones).

Niveles de logro:

Nivel	Descriptor
0.0 Nulo	Describe la IA como "un chatbot" o "un bot de WhatsApp" genérico. No distingue el agente conversacional del sistema de evaluación. Ante pregunta técnica concreta responde con generalidad o inventa capacidades.
0.2 Inicial	Menciona que hay "varios agentes" o "IA de voz" pero no puede explicar cómo funcionan ni por qué. Evade la pregunta de límites ("la IA ya casi no se equivoca") o de seguridad. KYC ausente.
0.4 Básico	Explica correctamente al menos un mecanismo central (agentes en paralelo por criterio, o encuestas de voz dinámicas) pero de forma superficial. Reconoce que las alucinaciones existen sin explicar mitigación. KYC mencionado solo como etiqueta.
0.6 Intermedio	Explica el mecanismo con causa-efecto: por qué agentes especializados dan consistencia, por qué el RAG ancla criterios, cómo el bot de encuestas profundiza. Nombra al menos un límite real y una mitigación concreta. KYC descrito a nivel de flujo (qué se verifica y cuándo).
0.8 Avanzado	Domina ambos productos a nivel arquitectura: separación evaluador/conversacional, escalabilidad de criterios sin reentrenamiento, trazabilidad por agente. Trata alucinaciones y seguridad proactivamente, antes de que el prospecto objete. Conecta KYC con la mecánica de cumplimiento (consentimiento, datos personales, resguardo).
1.0 Experto	Todo lo anterior y, además, calibra la profundidad técnica al interlocutor: responde objeciones técnicas concretas con precisión (sin generalidades ni invención), admite con naturalidad lo que el producto no hace, y usa los límites como evidencia de seriedad técnica, no como debilidad.

Banderas rojas (tope de 0.4 en esta capa si ocurren):

- Inventar una capacidad técnica que ningún producto tiene.
- Responder una pregunta técnica concreta con generalidad ("la IA aprende sola").
- Negar o minimizar las alucinaciones cuando el prospecto las plantea.

D2 — Comercial (20%)

Qué evalúa: Diferenciación frente a la competencia y claridad sobre la oferta específica de

Nativa. Beneficios concretos para el negocio del cliente: no solo qué hace el producto, sino qué gana el cliente con él.

Anclas de producto (evidencia válida en transcript):

- P1 diferenciación: consistencia garantizada vs. sesgo manual y vs. LLM judges sin estructura (drift); feedback granular y accionable ("qué revisar exactamente") vs. "mal, necesita mejorar" de la competencia; latencia 3-5 seg/respuesta vs. 30-60 seg secuencial, 100+ interacciones/hora; gobernanza auditable vs. caja negra.
- P2 diferenciación: qualitative-at-scale (miles de encuestas simultáneas con profundidad), de meses a días u horas, tasas de respuesta más altas, reducción de sesgo de muestra, ramificación dinámica, mapeo agregado atado a KPIs.
- Beneficio en lenguaje del cliente: qué decisión toma mejor, qué costo evita, qué riesgo reduce, qué velocidad gana.

Niveles de logro:

Nivel	Descriptor
0.0 Nulo	Describe features sin beneficio ("tiene agentes en paralelo") o beneficios vacíos ("te ayuda a ser más eficiente"). Cero diferenciación: lo dicho aplicaría a cualquier proveedor.
0.2 Inicial	Enumera beneficios de catálogo sin conectarlos al negocio del prospecto. Ante "¿en qué son distintos?" responde con adjetivos ("somos más completos") sin sustancia comparativa.
0.4 Básico	Articula al menos un diferenciador real (p. ej. feedback granular, o escala cualitativa) pero sin traducirlo a ganancia del cliente, o lo traduce a un beneficio genérico no anclado a lo que el prospecto dijo.
0.6 Intermedio	Diferencia con estructura comparativa explícita (manual/monolítico/caja negra vs. la propuesta de Nativa) y traduce ≥ 1 diferenciador a un beneficio concreto del negocio del prospecto (costo, velocidad, riesgo, calidad de decisión).
0.8 Avanzado	Diferenciación específica por producto y por objeción: elige el diferenciador que responde a lo que el prospecto acaba de plantear, no el de catálogo. Cuantifica el beneficio donde hay dato (latencia, throughput, tiempo de estudio) y lo expresa en la métrica que le importa al prospecto.
1.0 Experto	Todo lo anterior y convierte la diferenciación en criterio de compra: le da al prospecto la vara con la que comparar a cualquier competidor ("pregúntale a tu proveedor si puede auditar qué pesó en cada calificación"), de modo que la comparación misma favorece a Nativa.

Banderas rojas (tope de 0.4 en esta capa si ocurren):

- Descalificar a la competencia con adjetivos en lugar de contraste verificable.
- Prometer un beneficio cuantificado que no existe en la data disponible.
- Beneficio idéntico recitado dos veces sin adaptarse a lo que el prospecto respondió.

D3 — Estrategia (25%)

Qué evalúa: Conectar la propuesta con KPIs de éxito y resultados de negocio tangibles con **honestidad calibrada:** citar data real cuando existe, marcar claramente lo que es piloto, apoyarse en comparables del sector cuando no hay data propia — no se exige memorizar cifras exactas. Argumentar el cumplimiento regulatorio como parte del valor estratégico, no

solo como mecánica técnica. Y dimensionar algo transformacional: combinar al menos 3-4 servicios de Nativa (KYC, videollamada, simulador, evaluador, canal, automatización, consultoría) para vender un ecosistema, no una pieza aislada.

Ancias de honestidad calibrada (evidencia válida en transcript):

- **Data real citable:** WEF proyecta que 59 de cada 100 trabajadores necesitarán reskilling en 2030; IDC estima pérdidas potenciales de 5.5 billones USD por escasez de talento cualificado; vida media de un skill ≤ 5 años (12-18 meses en IA, IBM); latencia 3-5 seg y 100+ interacciones/hora del sistema de evaluación.
- **Piloto — debe marcarse como tal:** Conversational AI Qualitative Surveying está en fase de creación/alianza (sin compromiso de compra, co-diseño con aliados pioneros). Presentarlo como producto maduro con clientes en producción es fabricación.
- **Comparables del sector:** permitidos y valorados cuando no hay data propia, siempre presentados como comparables ("en el sector se observa..."), nunca como resultados de Nativa.
- KPIs conectables: tiempo de capacitación $\rightarrow$ competencia, costo por evaluación, cobertura de evaluación (100% vs. muestreo), tiempo de estudio cualitativo (meses $\rightarrow$ días), tasa de respuesta, calidad/representatividad de muestra.

Niveles de logro:

Nivel	Descriptor
0.0 Nulo	Ningún vínculo con KPIs ni resultados de negocio. O bien: inventa cifras, casos o clientes (fabricación anula la capa: 0.0 directo). Regulación ausente o tratada como estorbo. Vende una sola pieza.
0.2 Inicial	Menciona "ROI" o "impacto" como palabras, sin mecanismo causal ni métrica. Cita datos con atribución vaga o infla el estatus del piloto. Regulación reducida a "cumplimos con la ley".
0.4 Básico	Conecta la propuesta con ≥ 1 KPI plausible y usa ≥ 1 dato real, pero mezcla sin distinción lo probado, lo piloto y lo estimado. Combina 2 servicios como suma ("además tenemos..."), no como sistema.
0.6 Intermedio	Conecta con 2+ KPIs con mecanismo causal claro. Distingue explícitamente data real / piloto / comparable del sector al citar. Menciona regulación como requisito que Nativa resuelve. Combina 3 servicios con una lógica de conjunto incipiente.
0.8 Avanzado	Honestidad calibrada consistente: cita el dato real con fuente, marca el piloto sin que pierda atractivo ("justamente por eso la alianza pionera te conviene"), y usa comparables donde falta data propia. Argumenta la regulación como ventaja estratégica (auditabilidad, trazabilidad, gobernanza como razón para elegir a Nativa frente a cajas negras). Dimensiona un ecosistema de 3-4 servicios donde cada pieza potencia a las otras.
1.0 Experto	Todo lo anterior, articulado desde los KPIs del prospecto: la narrativa transformacional (ecosistema 3-4 servicios + cumplimiento como valor + evidencia calibrada) queda anclada a los resultados de negocio que el propio prospecto mencionó, con secuencia sugerida de adopción (por dónde empezar y por qué). El prospecto puede repetir el caso de negocio internamente sin ayuda.

Banderas rojas (0.0 directo en esta capa si ocurren):

- Inventar benchmarks, cifras, casos o clientes.
- Presentar el piloto (P2) como producto probado en producción con resultados propios.
- Atribuir a Nativa un comparable del sector.

D4 — Diagnóstico (20%)

Qué evalúa: Diagnosticar correctamente el problema real del cliente antes de proponer

cualquier solución: hacer las preguntas correctas en vez de asumir la respuesta de entrada. La solución llega después del diagnóstico, y anclada a él.

Conductas observables (evidencia válida en transcript):

- Preguntas de contexto antes de la primera propuesta (situación actual, cómo miden hoy, dónde duele, qué han intentado).
- Preguntas de segundo nivel que retoman la respuesta anterior (no checklist).
- Parafraseo explícito de lo que el prospecto dijo.
- Hipótesis verificada ("entiendo que el problema está en X más que en Y, ¿es así?") en lugar de asunción silenciosa.
- Propuesta formulada con referencia explícita a información que el prospecto compartió.

Niveles de logro:

Nivel	Descriptor
0.0 Nulo	Pitch de entrada: propone solución sin una sola pregunta de contexto, o asume el problema del cliente y no lo verifica en toda la llamada.
0.2 Inicial	Hace 1-2 preguntas de cortesía pero la propuesta ignora las respuestas: habría sido idéntica sin ellas.
0.4 Básico	Pregunta por el contexto y ajusta parcialmente la propuesta, pero se queda en el síntoma declarado sin explorar la causa, o pivota de tema sin profundizar lo que el prospecto abrió.
0.6 Intermedio	Secuencia diagnóstica reconocible: preguntas de contexto → ≥1 pregunta de segundo nivel sobre la respuesta anterior → propuesta que referencia explícitamente lo dicho. Al menos un parafraseo o verificación de hipótesis.
0.8 Avanzado	Baja del síntoma a la causa (proceso, incentivos, datos, estructura) con preguntas calibradas, verifica su hipótesis antes de proponer, e integra una corrección del prospecto ajustando el diagnóstico en tiempo real.
1.0 Experto	El diagnóstico produce una lectura que el prospecto no había articulado, referenciando 2-3 piezas específicas que compartió, y la propuesta se deriva visiblemente de esa lectura. El prospecto valida el diagnóstico ("exacto, eso es") antes de escuchar la solución.

Banderas rojas (tope de 0.4 en esta capa si ocurren):

- Proponer solución en los primeros turnos sin diagnóstico previo (proxy: primer 15% de turnos).
- Ignorar una corrección del prospecto y sostener el diagnóstico original.
- Preguntas en frío tipo checklist sin retomar nada de lo respondido.

D5 — Consultoría y servicios (15%)

Qué evalúa: Explicar el modelo de consultoría y servicios profesionales de Nativa — cómo se acompaña la implementación, alcance y metodología de trabajo con el cliente — como parte de la propuesta de valor, no solo la tecnología.

Anclas de producto (evidencia válida en transcript):

- Ciclo completo de Nativa: diagnosticamos + diseñamos + implementamos, punta a punta ("back to front").
- P1 como servicio, no solo software: definición conjunta de criterios y rúbricas, matriz de nivel de logro por puesto, robustez para cualquier tema de capacitación, dashboard como "una verdad".
- P2 como servicio acompañado: el aliado define objetivo, audiencia y 5 preguntas clave; Nativa opera el levantamiento y entrega análisis agregado de insights; modelo de alianza de co-diseño ("afinar la solución de acuerdo a tus necesidades", sin compromiso de compra).
- Metodología de trabajo: qué pone el cliente, qué pone Nativa, cómo se itera, cómo se mide el éxito del engagement.

Niveles de logro:

Nivel	Descriptor
0.0 Nulo	Presenta a Nativa como proveedor de software que se entrega y ya. Ante "¿y cómo trabajaríamos?" no tiene respuesta o improvisa vaguedades.
0.2 Inicial	Menciona "acompañamiento" o "consultoría" como etiqueta, sin describir qué implica ni cómo se estructura.
0.4 Básico	Describe el ciclo diagnosticamos-diseñamos-implementamos como slogan, pero no puede aterrizar qué pasa en cada fase ni qué rol juega el cliente.
0.6 Intermedio	Explica el modelo de trabajo con roles claros (qué define el cliente, qué opera Nativa) para al menos un producto — p. ej. el flujo objetivo→audiencia→preguntas→levantamiento→análisis de P2, o la definición conjunta de criterios y rúbricas de P1.
0.8 Avanzado	Presenta la consultoría como diferenciador: el valor no es solo la herramienta sino el método (diagnóstico previo, co-diseño de criterios, iteración, medición del engagement). Describe alcance y siguientes pasos concretos y realistas para el caso del prospecto.
1.0 Experto	Todo lo anterior y posiciona el modelo de servicios como reducción de riesgo para el prospecto: la metodología (empezar por diagnóstico, piloto acotado, alianza de co-diseño) es la respuesta natural a sus objeciones de incertidumbre, y queda claro por qué comprar el ecosistema con acompañamiento supera comprar tecnología suelta.

Banderas rojas (tope de 0.4 en esta capa si ocurren):

- Prometer alcances o tiempos de implementación inventados.
- Reducir la consultoría a "te damos soporte".
- Contradecir el modelo de trabajo real (p. ej. afirmar que el cliente no necesita definir nada).

Notas de diseño (para revisión, no para los agentes)

1. **Pesos:** propuesta inicial 20/20/25/20/15. Estrategia lleva el mayor peso porque concentra tres criterios (KPIs + regulatorio + ecosistema) y es donde la iniciativa pone la métrica de impacto.
2. **Fabricación:** en D3 la fabricación es 0.0 directo (consistente con la bandera global de benchmarks inventados en las rúbricas previas); en las demás capas las banderas operan como tope de 0.4.

3. **Conducta vs. resultado:** los niveles miden técnica y comunicación observables en transcript, no si el prospecto simulado "compró" — coherente con el principio de comportamiento sobre resultado.
4. **Proxy de turnos:** el criterio temporal de D4 (pitch de entrada) usa posición proporcional en turnos, como en las rúbricas anteriores.
5. **Extensibilidad:** cada bloque es autocontenido para asignarse a un agente evaluador independiente; agregar productos futuros solo requiere ampliar las anclas, no los niveles.