

Rúbrica MECE de codificación de imagen país (4D Buhmann & Ingenhoff) para tuits sobre México durante el Mundial FIFA 2026

Resumen

- Se entrega un codebook operativo de tres rúbricas ordinales (0-5) — dimensión simpática/emocional, estética y funcional — más una rúbrica binaria (0/1) para la cuarta dimensión, la **saliencia de violencia** (detección de presencia del tema, sin valencia). Todo construido con convenciones estándar de evaluación referida a criterios y análisis de contenido: descriptores por niveles, principio de mejor ajuste (*best-fit*) y lectura descendente, resolviendo el problema del nivel 0 mediante una escala híbrida ausencia/valencia (0 = ausencia; 1-2 = negativa; 3 = neutral/mixta; 4-5 = positiva).
- La advertencia metodológica central es que el 0 mezcla "ausencia de la dimensión" con "extremo bajo de valencia"; la solución defendible ante un jurado es tratar el 0 como categoría de no-aplica/missing y reportar por separado presencia (dummy) y valencia condicional (1-5) como análisis de robustez.
- El protocolo de fiabilidad recomendado es doble codificación de una submuestra con Krippendorff's alpha ordinal (Krippendorff 2004, p. 241: $\alpha \geq .800$ firme; $.667 \leq \alpha < .800$ tentativo; $< .667$ descartar), con el LLM tratado como un codificador más validado contra humanos.

Hallazgos clave

1. **El modelo 4D es un constructo actitudinal** (Ajzen: cogniciones + afectos). Fue propuesto por Alexander Buhmann y Diana Ingenhoff y publicado en Buhmann & Ingenhoff (2015), *The 4D Model of the country image*, International Communication Gazette 77(1): 102-124 (doi:10.1177/1748048514556986) — el primer modelo que operacionaliza las dimensiones combinando indicadores formativos y reflectivos en un modelo de especificación mixta (*mixed-specified*). Las tres dimensiones que se codifican son: funcional y estética (componente cognitivo, con indicadores formativos) y simpática/emocional (componente afectivo, con indicadores reflectivos). Esta distinción cognitivo/afectivo es la base conceptual del MECE inter-dimensión.
2. **Los indicadores formativos de Buhmann & Ingenhoff son verificables y verbatim** (instrumento de 21 ítems formativos: 12 funcionales, 5 normativos, 4 estéticos, + 3 reflectivos emocionales), lo que permite anclar objetivamente qué "toca" cada dimensión.
3. **Las convenciones de rúbricas referidas a criterios son directamente trasladables al content analysis**: descriptores por niveles de logro, marcado positivo, lectura descendente, mejor ajuste, y la regla de que no es necesario cumplir todos los indicadores de un nivel para otorgarlo.

4. **Krippendorff's alpha ordinal es el estadístico correcto** (no la métrica nominal, que inflaría el desacuerdo en escala ordenada); el kappa ponderado cuadrático de Cohen es alternativa válida con exactamente dos codificadores.
5. **El LLM como codificador es metodológicamente aceptable** si se valida contra codificadores humanos con las mismas métricas IRR, con temperatura baja, pidiendo razonamiento antes de la etiqueta, y con la rúbrica reescrita para comprensión de máquina.

Desarrollo

(a) Principios de diseño de la rúbrica (evaluación referida a criterios)

La rúbrica sigue convenciones establecidas en la evaluación referida a criterios (*criterion-referenced assessment*) y en la construcción de codebooks de análisis de contenido (Neuendorf, *The Content Analysis Guidebook*; Krippendorff, *Content Analysis*):

1. **Evaluación referida a criterios, no normativa (criterion-related, not norm-referenced).** Cada tuit se juzga contra descriptores fijos, no contra otros tuits. → Cada dimensión es una escala independiente; un tuit puede ser 5 en estética y 0 en funcional.
2. **Criterios evaluados por separado (independencia de criterios).** Una dimensión no compensa a otra. → Las tres dimensiones son tres variables separadas; no se promedian ni se compensan entre sí. Se codifica cada dimensión por su propia rúbrica.
3. **Enfoque de "mejor ajuste" (best-fit approach).** Cuando una unidad de análisis cae entre dos descriptores, ambos se releen y se elige el que describe con más precisión el contenido; el nivel otorgado debe reflejar el balance dominante de la evidencia. → Regla operativa central: se asigna el nivel cuyo descriptor captura el peso dominante del tuit, no el que coincide con un fragmento aislado.
4. **Marcado positivo y lectura descendente (positive marking, top-down reading).** El codificador lee los descriptores desde el nivel más alto hacia abajo hasta llegar al primero que describe el contenido. → El codificador (humano o LLM) lee de 5 hacia 0 y se detiene en el primer descriptor que aplica.
5. **No es necesario cumplir todos los indicadores de un nivel para otorgarlo.** → Los niveles bajos NO exigen todo lo del nivel superior; un nivel se otorga por ajuste dominante, no por checklist exhaustivo.
6. **Los descriptores altos no exigen perfección.** → El nivel 5 no requiere un tuit "perfecto" de fascinación; basta con la presencia clara e inequívoca de afecto/atracción máxima.
7. **Los descriptores de nivel bajo pueden describir el polo negativo del constructo.** → Legítima que los niveles 1-2 codifiquen valencia negativa (el "extremo bajo" del constructo), práctica común en escalas evaluativas.
8. **Descriptores conductuales observables y números enteros.** Se juzga por evidencia observable en el texto y se registran solo valores enteros. → Los descriptores se redactan

como rasgos observables del tuit (palabras, actos de habla, objetos referidos), y la variable es ordinal entera 0-5.

9. **Fronteras entre niveles decididas por intensidad/dominancia.** El nivel superior de un par adyacente se otorga cuando las cualidades se demuestran en mayor medida; el inferior, en menor medida. → Se traslada a las notas de desempate por pares adyacentes (0-1, 1-2, ...).

(b) Resolución del problema del nivel 0 y estructura general de la escala

El problema. Se pide que 0 sea *simultáneamente* "ausencia de la dimensión" y "extremo bajo de la escala". Pero en tuits reales existe contenido que **toca** la dimensión con **valencia negativa** ("la comida mexicana es asquerosa" toca la estética, negativamente). Si 0 = ausencia y 0 = lo más bajo, se colapsan dos cosas conceptualmente distintas: **presencia/ausencia** (¿el tuit activa la dimensión?) y **valencia/intensidad** (¿qué tan positiva o negativa es?). Esto viola parcialmente el principio MECE porque la categoría 0 dejaría de ser mutuamente excluyente respecto a "presente pero muy negativo".

La solución adoptada (manteniendo el formato 0-5 solicitado): escala híbrida ausencia + valencia.

Valor	Significado estructural	Naturaleza
0	Ausencia: el tuit no toca la dimensión en absoluto	Categoría cualitativamente distinta (no-aplica / missing potencial)
1	Presencia con valencia fuertemente negativa	Escala de valencia (presente)
2	Presencia con valencia negativa moderada	Escala de valencia (presente)
3	Presencia neutral, mixta o ambivalente	Escala de valencia (presente)
4	Presencia con valencia positiva	Escala de valencia (presente)
5	Presencia con valencia fuertemente positiva / fascinación	Escala de valencia (presente)

Esta estructura es consistente con codebooks de sentimiento de 5-6 puntos ampliamente usados: la escala ordinal de cinco puntos de valencia (Highly Negative, Slightly Negative, Neutral, Slightly Positive, Highly Positive) y la tarea SemEval-2017 Task 4, subtask C, definida verbatim por Rosenthal, Farra & Nakov (2017) (ACL Anthology S17-2088): "*Subtask C: Given a tweet and a topic, classify the sentiment conveyed... on a five-point scale: STRONGLYPOSITIVE, WEAKLYPOSITIVE, NEUTRAL, WEAKLYNEGATIVE, and*

STRONGLYNEGATIVE." Un modelo comercial de taxonomía de marca país (Bloom Consulting) usa además exactamente una escala 0-5 de valencia (0 extremadamente negativo → 5 extremadamente positivo). Nuestra innovación es reservar el 0 para *ausencia* y correr la valencia a 1-5, lo cual es defendible pero exige documentación.

La advertencia metodológica y cómo defenderla ante un jurado. El punto débil es que **el 0 no es ordinalmente contiguo al 1**: pasar de "ausencia" (0) a "muy negativo" (1) no es un incremento de una unidad en la misma latente, mientras que de 1→2→3→4→5 sí lo es (valencia creciente). Un salto de 0 a 1 mezcla dos dimensiones latentes (activación + valencia). Mitigaciones a documentar en la tesis:

1. **Tratar el 0 como missing / no-aplica en los análisis de valencia.** Para la mediana diaria y la distribución porcentual de valencia, calcular dos versiones: (i) con 0 incluido (imagen "cruda" incluyendo silencio dimensional) y (ii) condicional a presencia (solo 1-5, "¿cuando se habla de la dimensión, qué tan positiva es?"). Reportar ambas.
2. **Descomponer en dos variables de robustez:** una variable dummy de **presencia** (presence: 0 = ausencia, 1 = niveles 1-5) y una variable de **valencia condicional** (1-5, definida solo si presencia = 1). Esto separa limpiamente los dos constructos y permite análisis MECE puro por separado, tal como el content analysis (Neuendorf) recomienda categorías/niveles exhaustivos y mutuamente excluyentes.
3. **Para la reliability ordinal**, calcular el alpha de dos maneras: sobre la escala completa 0-5 y sobre la subescala 1-5 (excluyendo pares donde ambos codificadores pusieron 0), porque incluir muchos 0 puede inflar artificialmente el acuerdo (prevalencia alta de una categoría).
4. **Reportar la saliencia dimensional** (proporción diaria de tuits con nivel ≥ 1 en cada dimensión) como estadístico separado, análogo a la cuarta variable de saliencia de violencia.

Con estas mitigaciones, la escala 0-5 solicitada se conserva como instrumento de recolección, pero el análisis reconoce explícitamente la naturaleza bidimensional del 0 — que es exactamente el tipo de transparencia metodológica que un jurado de Relaciones Internacionales espera.

Nivel de medición (level of measurement). La variable resultante es **ordinal** en 1-5 (más 0 como categoría especial). No se debe tratar como intervalo: la distancia 1→2 no es necesariamente igual a 4→5 en unidades psicológicas. Por eso la mediana + distribución porcentual son los estadísticos correctos, y el alpha debe usar la métrica ordinal.

(c) Las tres rúbricas completas

RÚBRICA 1 — ATMÓSFERA DE MÉXICO: DIMENSIÓN SIMPÁTICA / EMOCIONAL
(sympathetic/emotional dimension of Mexico's country image)

Descripción de la dimensión. Componente **afectivo** del modelo 4D. Buhmann & Ingenhoff la definen como los sentimientos generales de simpatía y fascinación hacia un país — su "ability to attract". Operacionalizada con **indicadores reflectivos** (Buhmann & Ingenhoff 2015; tres ítems retenidos tras EFA, cargas $\geq .70$): fascinación por el país (*country fascination*, carga .78), simpatía por el país (*sympathy for the country*, carga .89) y atractivo del país (*country attractiveness*, carga .73); fiabilidad Cronbach's $\alpha = .77$, AVE = .69. Mide la **emoción del emisor hacia México y su gente**: agrado, calidez, fascinación, atracción afectiva, hospitalidad experimentada, deseo de volver/quedarse — o sus contrarios (rechazo, desprecio, miedo afectivo, hostilidad). **Clave distintiva**: capta el *estado afectivo del hablante hacia el país*, no un juicio sobre un objeto cultural concreto (eso es estético) ni sobre una competencia institucional (eso es funcional).

Indicadores/subtemas que cuentan como "tocar" la dimensión (INCLUIDOS): expresiones de agrado o cariño hacia México/los mexicanos ("I love this country", "me encanta la gente"); fascinación/encanto afectivo ("I'm obsessed with Mexico"); atracción y deseo de volver o quedarse ("I never want to leave", "ya quiero regresar"); percepción de calidez/hospitalidad de la gente ("the friendliest people I've ever met"); orgullo afectivo o identificación emocional; y sus contrarios: rechazo/desprecio ("I hate it here"), miedo afectivo o incomodidad emocional hacia el país/gente ("this place scares me"), decepción afectiva.

EXCLUIDOS (van a otra dimensión): juicio sobre un bien cultural concreto sin emoción hacia el país (→ estética); evaluación de infraestructura/organización/seguridad institucional (→ funcional); mención neutra de un hecho violento sin afecto (→ saliencia de violencia). El miedo *afectivo difuso* hacia el país ("I'm terrified of Mexico") es simpática negativa; la *crítica a la gestión de seguridad* ("the police did nothing") es funcional; el *reporte del hecho* ("a shooting near the stadium") es saliencia.

Nivel Descriptor MECE (rasgo observable)

0	El tuit no expresa ninguna emoción del emisor hacia México ni su gente . Puede tratar de fútbol, logística o cultura sin carga afectiva hacia México.
1	Emoción fuertemente negativa hacia México o su gente : odio, desprecio, rechazo explícito, miedo afectivo intenso u hostilidad dirigidos a México ("I hate this country" [en referencia a México], "asco de país, asco de gente").
2	Emoción negativa moderada hacia México o su gente : desagrado, decepción, incomodidad, frialdad o ligera antipatía hacia México ("kind of disappointed with the vibe in Mexico", "no me sentí cómodo aquí" [en México]).
3	Emoción neutral, mixta o ambivalente hacia México o su gente : coexisten afectos positivos y negativos hacia México, o afecto tibio/indeciso ("mixed feelings about the people here in Mexico", "unos mexicanos amables, otros no").
4	Emoción positiva hacia México o su gente : agrado claro, simpatía, calidez percibida, gusto por México sin llegar a fascinación superlativa ("really enjoying the friendly atmosphere in Mexico", "buena onda la gente mexicana").
5	Emoción fuertemente positiva / fascinación por México o su gente : amor, encantamiento, atracción máxima, deseo intenso de volver o quedarse en México, superlativos afectivos ("I'm in love with Mexico and its people", "la gente mexicana es la más cálida del mundo, no me quiero ir").

Ejemplos de tuits por nivel:

- **0**: "Mexico plays Argentina tomorrow at Estadio Azteca. Kickoff 8pm." / "El estadio de Guadalajara tiene capacidad para 48 mil."
- **1**: "I hate it here, worst people ever, can't wait to leave this country." / "Qué asco de país, no vuelvo nunca."
- **2**: "Kind of underwhelmed by the vibe tbh, people weren't as warm as I expected." / "La verdad no me latió mucho la gente, medio secos."
- **3**: "Mixed feelings — some locals were super kind, others treated us badly." / "Unos súper amables y otros bien groseros, no sé qué pensar."
- **4**: "Really enjoying my time here, Mexicans are so welcoming!" / "Me está encantando, la gente es bien cálida."
- **5**: "I am absolutely in love with Mexico and its people. The warmest humans on earth — I never want to go home. 🇲🇽" / "México me robó el corazón, la gente más hermosa del mundo, ya quiero volver."

Notas de desempate por pares adyacentes (best-fit tie-breaking):

- **0 vs 1:** Si el tuit menciona al país/gente pero sin ninguna carga afectiva del emisor → 0. Si hay hostilidad/odio/miedo afectivo explícito hacia el país o su gente → 1. Ante duda, otorgue 0 solo si no hay *ningún* marcador emocional dirigido a México.
 - **1 vs 2:** Otorgue 1 cuando el afecto negativo es intenso, categórico o con lenguaje de odio/desprecio ("hate", "asco", "disgusting people"). Otorgue 2 cuando es tibio, matizado o expresado como decepción/incomodidad ("meh", "no me convenció", "a bit cold").
 - **2 vs 3:** Otorgue 2 si el balance neto es negativo. Otorgue 3 si conviven de forma equilibrada afectos positivos y negativos, o si el afecto es genuinamente indeciso/ambivalente.
 - **3 vs 4:** Otorgue 3 si hay mezcla real o neutralidad afectiva. Otorgue 4 si el balance neto es claramente positivo aunque contenga un matiz negativo menor.
 - **4 vs 5:** Otorgue 4 para agrado/simpatía normal. Otorgue 5 solo cuando haya intensidad superlativa, fascinación, amor declarado o deseo intenso de volver/quedarse (marcadores: "in love", "obsessed", "best country ever", "no me quiero ir", emojis de corazón/llanto emotivo). El nivel 5 no exige perfección redaccional, solo intensidad afectiva inequívoca.
-

RÚBRICA 2 — IMAGEN CULTURAL DE MÉXICO: DIMENSIÓN ESTÉTICA (aesthetic dimension of Mexico's country image)

Descripción de la dimensión. Componente **cognitivo**. Buhmann & Ingenhoff la definen como las creencias específicas sobre las cualidades estéticas y la belleza/atractivo de un país como lugar **cultural y escénico**. Se añadió al modelo de reputación corporativa precisamente porque los atributos de Smith de "public culture, traditions and territory" no encajaban en las dimensiones funcional o normativa. Operacionalizada con cuatro indicadores formativos verbatim (Buhmann & Ingenhoff 2015, Tabla II): bienes culturales (*cultural goods*, peso .25), gastronomía (*culinary*, peso .28), historia y tradición (*history and tradition*, peso .29 — el factor de mayor peso en el estudio de EE.UU./viaje), y paisajes/escenografía (*landscapes and scenery*, peso .18). **Clave distintiva:** capta un *juicio evaluativo sobre el objeto cultural/escénico* (la comida, la música, las ruinas, el paisaje), no la emoción del hablante hacia el país en general (eso es simpática).

Indicadores/subtemas INCLUIDOS: gastronomía y bebida (tacos, mole, mezcal, comida callejera); bienes culturales y arte (muralismo, artesanía, arquitectura, museos, Frida Kahlo); historia y tradiciones/costumbres (Día de Muertos, ruinas prehispánicas, herencia azteca/maya, mariachi); música y danza como cultura; paisajes y belleza escénica (playas, cenotes, desiertos, ciudades coloniales); deporte *como fenómeno cultural/estético* (la fiesta, el colorido, el folclore del aficionado) — no el resultado deportivo en sí.

EXCLUIDOS: emoción difusa hacia el país/gente sin referirse a un objeto cultural (→ simpática); infraestructura, economía, organización del torneo, transporte (→ funcional); mención de violencia (→ saliencia). Ejemplo de frontera: "the food scene is world-class" es estético 5; "I love Mexico" es simpática; "the stadium wifi is great" es funcional.

Nivel Descriptor MECE (rasgo observable)

0	El tuit no evalúa ningún objeto cultural, gastronómico, histórico, artístico o escénico de México.
1	Juicio fuertemente negativo sobre la cultura, gastronomía, historia o paisaje de México: desprecio o repulsión hacia el objeto cultural mexicano ("Mexican food is disgusting garbage", "el arte mexicano es feísimo").
2	Juicio negativo moderado sobre un objeto cultural mexicano: crítica o baja valoración sin repulsión total ("the tacos in Mexico were kind of bland", "las pirámides mexicanas están descuidadas").
3	Juicio neutral, mixto o meramente descriptivo sobre un objeto cultural mexicano: lo menciona/describe sin valencia clara, o mezcla elogio y crítica ("Mexican mole is interesting, some dishes great, others too spicy for me").
4	Juicio positivo sobre un objeto cultural mexicano: valoración favorable ("the tacos here in Mexico are really good", "bonita la arquitectura colonial mexicana").
5	Juicio fuertemente positivo / fascinación estética por la cultura de México: elogio superlativo, riqueza cultural excepcional, belleza deslumbrante ("Mexico has the most breathtaking cuisine and culture on the planet", "el arte y la historia de México son lo más impresionante que he visto").

Ejemplos de tuits por nivel:

- **0:** "Traffic to the stadium was heavy today." / "México juega el domingo."
- **1:** "Mexican food is disgusting, worst cuisine I've ever tried." / "La comida acá está asquerosa, no sé cómo la comen."
- **2:** "The tacos were honestly kind of bland and greasy." / "Las pirámides estaban muy descuidadas, decepcionante."
- **3:** "Tried mole for the first time — interesting flavor, not sure if I liked it or not." / "La música de mariachi es peculiar, a ratos linda a ratos cansada."
- **4:** "Beautiful colonial architecture in the city center, really nice." / "Qué rico el mole poblano, buena comida."

- **5:** "Mexico has the most stunning culture on earth — the food, the murals, Día de Muertos, the ruins... absolutely breathtaking. 🍽️🎨" / "La gastronomía, el arte y la historia de México son simplemente lo más impresionante del mundo."

Notas de desempate por pares adyacentes:

- **0 vs 1:** Si no se refiere a ningún objeto cultural/escénico → 0. Si evalúa negativamente un objeto cultural → 1. Ante duda, 0 solo si no hay *ningún* referente cultural/gastronómico/histórico/escénico.
- **1 vs 2:** Otorgue 1 ante repulsión/desprecio categórico ("disgusting", "asqueroso", "garbage"). Otorgue 2 ante crítica moderada o valoración baja ("bland", "descuidado", "overrated").
- **2 vs 3:** Otorgue 2 si el balance neto sobre el objeto es negativo. Otorgue 3 si es puramente descriptivo sin valencia, o mezcla equilibrada de elogio y crítica.
- **3 vs 4:** Otorgue 3 ante descripción neutra o mezcla. Otorgue 4 si el balance neto es positivo.
- **4 vs 5:** Otorgue 4 para valoración favorable normal ("good", "nice", "rico", "bonito"). Otorgue 5 solo ante superlativos o fascinación estética ("breathtaking", "the best in the world", "lo más impresionante", acumulación de varios objetos culturales elogiados).

RÚBRICA 3 — PERSPECTIVA POLÍTICA DE MÉXICO: DIMENSIÓN FUNCIONAL (functional dimension of Mexico's country image)

Descripción de la dimensión. Componente **cognitivo**. Buhmann & Ingenhoff la definen como las creencias específicas sobre las **competencias y competitividad** de un país, su **efectividad y desempeño político y económico**. Operacionalizada con 12 indicadores formativos verbatim (Buhmann & Ingenhoff 2015, Tabla II): innovación del país, productos y servicios nacionales, competencia de las empresas nacionales, prosperidad/riqueza, fuerza económica (*economic strength*, peso .31, significativo), mercados laborales, competencias del liderazgo político (*competences of political leadership*, peso .43 — el factor dominante en el estudio de EE.UU./viaje), estabilidad política (*political stability*, peso .33, significativo), infraestructura, innovación en investigación, oportunidades educativas y nivel educativo. Para el contexto Mundial 2026 se añaden como subtemas funcionales: organización del torneo, logística, transporte, y **seguridad institucional entendida como competencia de gestión** (no el hecho violento). **Clave distintiva:** capta la *eficacia/competencia institucional u organizativa*, no la emoción ni el objeto cultural.

Nota sobre dependencia de muestra: el segundo estudio de Buhmann (2016) reportó pesos distintos para el mismo instrumento — allí "quality of products and services explains most of the variance" de la dimensión funcional, seguido de estabilidad política e infraestructura. Es decir, el indicador funcional dominante varía con la muestra (liderazgo político vs. calidad de

productos), lo que refuerza que en tuits del Mundial los subtemas dominantes serán probablemente organización, seguridad-gestión e infraestructura.

Indicadores/subtemas INCLUIDOS: economía, prosperidad, productos/servicios, empresas, mercados laborales; política, estabilidad política, competencia del gobierno/liderazgo, instituciones; infraestructura (estadios, aeropuertos, transporte, wifi, hoteles); ciencia, investigación, innovación, educación; **organización y logística del torneo** (fluidez de accesos, boletaje, señalización, filas); **gestión de la seguridad** como desempeño institucional ("el operativo funcionó", "la policía respondió rápido", "Plan Kukulcán bien ejecutado" o su contrario "seguridad improvisada", "caos en los accesos").

EXCLUIDOS: emoción hacia el país/gente (→ simpática); comida/cultura/paisaje (→ estética); **la mención del hecho violento en sí** — un tiroteo, una desaparición, un bloqueo — cuando se reporta como evento (→ saliencia de violencia, variable aparte). La **frontera funcional/violencia** es crítica: "there was a shooting near the fan zone" = saliencia (hecho); "the authorities completely failed to secure the fan zone" = funcional negativo (juicio sobre la competencia de gestión). Un mismo tuit puede puntuar en ambas (son variables distintas).

Nivel Descriptor MECE (rasgo observable)

0	El tuit no evalúa ninguna competencia económica, política, institucional, de infraestructura, educativa/científica ni de organización/logística/gestión de seguridad de México.
1	Juicio fuertemente negativo sobre la competencia institucional u organizativa de México: fracaso rotundo, colapso, incompetencia grave de instituciones o autoridades mexicanas ("total institutional collapse in Mexico, nothing works, the Mexican government completely failed").
2	Juicio negativo moderado sobre la competencia institucional u organizativa de México: deficiencia, ineficiencia o crítica acotada ("the transport to the stadium in Mexico was poorly organized", "los accesos en la sede mexicana fueron un desorden").
3	Juicio neutral, mixto o descriptivo sobre el desempeño institucional u organizativo de México: lo menciona sin valencia clara, o mezcla aciertos y fallas ("Mexico's security operation was huge but caused long queues").
4	Juicio positivo sobre la competencia institucional u organizativa de México: eficacia favorable ("the stadium infrastructure in Mexico is excellent", "el operativo mexicano estuvo bien organizado").
5	Juicio fuertemente positivo sobre la competencia institucional u organizativa de México: excelencia excepcional ("Mexico's organization is flawless, world-class infrastructure, the best-run tournament ever", "logística impecable, México dio cátedra").

Ejemplos de tuits por nivel:

- **0:** "Can't wait for the match tonight!" / "Amo a este país" (esto es simpática, no funcional).
- **1:** "Complete chaos — no security, no organization, the government failed spectacularly." / "Un desastre total, no funcionó nada, puro caos institucional."
- **2:** "Getting into the stadium was disorganized, long unclear lines." / "El transporte al estadio estuvo mal planeado."
- **3:** "Massive 99,000-strong security deployment, though it did create long entry queues." / "Enorme operativo de seguridad, aunque hubo filas larguísimas."
- **4:** "The new Estadio Azteca infrastructure is genuinely excellent and well-run." / "Los accesos y el transporte funcionaron muy bien."
- **5:** "Honestly the best-organized World Cup logistics I've ever seen — flawless infrastructure and security. Mexico delivered." / "Organización impecable, infraestructura de primer nivel, México dio cátedra."

Notas de desempate por pares adyacentes:

- **0 vs 1:** Si no hay juicio sobre competencia institucional/organizativa → 0. Si hay crítica de fracaso institucional → 1. Recordar: el mero reporte de un hecho violento sin juicio de gestión NO es funcional (es saliencia) → puede ser 0 en funcional.
- **1 vs 2:** Otorgue 1 ante fracaso rotundo/colapso/incompetencia categórica ("nothing works", "total failure", "desastre total"). Otorgue 2 ante deficiencia acotada o crítica moderada de una función específica.
- **2 vs 3:** Otorgue 2 si el balance neto es negativo. Otorgue 3 si es descriptivo sin valencia o mezcla equilibrada de logros y fallas.
- **3 vs 4:** Otorgue 3 ante descripción neutra o mixta. Otorgue 4 si el balance neto es positivo.
- **4 vs 5:** Otorgue 4 para eficacia favorable normal ("good", "well-organized", "funcionó bien"). Otorgue 5 solo ante excelencia superlativa o comparación de liderazgo mundial ("flawless", "best-run ever", "de primer nivel mundial", "cátedra").
- **Frontera funcional vs saliencia de violencia (regla transversal):** si el tuit *reporta* el hecho violento → codificar en saliencia; si *juzga la gestión/respuesta institucional* ante la violencia → codificar en funcional (valencia según el juicio). Ambas pueden coexistir.

RÚBRICA 4 — SALIENCIA DE VIOLENCIA EN MÉXICO (salience of violence in Mexico — binaria 0/1)

Descripción de la dimensión. A diferencia de las tres anteriores, esta variable no pertenece al modelo 4D sino a la teoría de agenda-setting de primer nivel (McCombs & Shaw 1972): mide la **transferencia de atención**, no la postura. Registra si el tuit **habla del tema de violencia/inseguridad en México**, sin importar la valencia ni la posición del emisor — un tuit

que desmiente el estereotipo ("Mexico is way safer than the media says") cuenta igual que uno que lo confirma, porque ambos mantienen el tema en la conversación. Por eso la escala es **binaria de presencia (0/1)**, no ordinal: la saliencia se construye en el agregado, como **proporción diaria** de tuits con valor 1 sobre el total de tuits sobre México (variable de razón). La valencia del contenido violento no se pierde: la capturan las otras dimensiones cuando aplican (p. ej., miedo afectivo → simpática; juicio sobre la gestión de seguridad → funcional).

Indicadores/subtemas INCLUIDOS (→ 1): mención de hechos violentos contemporáneos en México (tiroteos, homicidios, secuestros, desapariciones, extorsión, bloqueos, enfrentamientos); actores del crimen organizado (cárteles, narco, CJNG, sicarios); inseguridad o peligrosidad como tema ("Mexico is dangerous", "cuidado con la inseguridad", "is it safe to travel to Monterrey?"); advertencias de seguridad y travel warnings referidas a crimen/violencia; experiencias personales de victimización (asalto, robo); **desmentidos y refutaciones del tema** ("felt totally safe, the violence narrative is exaggerated" → 1, el tema está presente); preguntas sobre el riesgo ("should I be worried about cartels?" → 1); miedo explícitamente anclado en crimen/violencia ("I'm scared of the cartels" → 1, y además simpática negativa).

EXCLUIDOS (→ 0): violencia **metafórica o deportiva** ("México masacró a Argentina 3-0", "we killed it tonight", "qué golazo, los destrozamos"); violencia **histórica o cultural** sin referencia contemporánea (sacrificios aztecas, la Revolución, un mural sobre la Conquista → estética); violencia **en otros países** o sin vínculo con México; menciones de seguridad **puramente logísticas sin referencia a crimen/violencia** ("the security check line took forever" → 0, es funcional); la palabra "peligro/danger" aplicada a cosas no criminales (una jugada peligrosa, comida picante "peligrosa").

Nivel Descriptor MECE (rasgo observable)

0	El tuit no menciona ni alude a violencia, crimen o inseguridad contemporáneas en México — ni para afirmarla, ni para negarla, ni para preguntar por ella.
1	El tuit menciona o alude a violencia, crimen o inseguridad contemporáneas en México , en cualquier valencia y postura: reporte, opinión, miedo, advertencia, pregunta, experiencia personal o desmentido.

Ejemplos de tuits por nivel:

- **0:** "The tacos in Guadalajara are incredible!" / "México masacró a Argentina, qué partidazo." / "Long lines at the stadium security check, poorly organized." / "El mural de la Conquista en Palacio Nacional es impresionante."
- **1:** "Reports of a shooting near the fan zone in Monterrey tonight." / "Bloqueos del CJNG en Jalisco, tengan cuidado." / "Honestly Mexico feels way safer than the news made me

believe — zero problems so far." / "Is it safe to take an Uber at night in CDMX? Worried about crime." / "Nos asaltaron saliendo del estadio."

Notas de desempate (0 vs 1):

- **Metáfora deportiva vs hecho:** si el verbo violento describe el juego o el marcador → 0. Si describe un hecho criminal o riesgo real → 1. Ante duda, pregunta decisoria: ¿un lector entendería que ocurrió o puede ocurrir un acto de violencia real en México? Sí → 1; no → 0.
- **Desmentido:** negar la violencia ES hablar de violencia → 1. Este es el caso de desempate más contraintuitivo; entrenarlo explícitamente con codificadores y LLM.
- **Seguridad logística vs seguridad-crimen:** filas, revisiones, operativos mencionados solo como logística → 0 (funcional). Si el tuit vincula el operativo con crimen, cárteles o riesgo de violencia ("massive deployment because of cartel threats") → 1 (y funcional si además juzga la gestión).
- **Violencia histórica/cultural:** referencia a violencia del pasado como patrimonio o historia → 0 (probablemente estética). Si el tuit la conecta con el presente ("this country has always been violent, nothing's changed") → 1.
- **Geografía:** violencia en otro país o genérica sin anclaje en México → 0. Ante ambigüedad de lugar en un corpus filtrado por México, si el contexto razonable del hilo es México → 1.

Indicador agregado. Saliencia de violencia diaria = (tuits con valor 1 ÷ total de tuits sobre México del día) × 100. Es la variable de razón del diseño; admite series de tiempo, detección de puntos de quiebre y correlación con eventos (partidos, incidentes, notas virales), replicando la lógica correlacional de agenda-setting.

(d) Reglas de frontera inter-dimensión (MECE inter-dimensión)

1. **Cada dimensión se codifica por separado (tres variables, no una).** Un tuit puede activar 0, 1, 2 o las 3 dimensiones. "The tacos are amazing and I love these people, but the stadium logistics were a disaster" = estética 5, simpática 5, funcional 2. No se fuerza una única etiqueta.
2. **Estética vs simpática (objeto cultural vs emoción hacia el país).** Pregunta decisoria: ¿el tuit *evalúa un objeto cultural/escénico concreto* (comida, arte, historia, paisaje) o *expresa el afecto del hablante hacia México/su gente*? Lo primero es estética; lo segundo, simpática. "The cuisine is stunning" → estética. "I love Mexico" → simpática. Si hace ambas, ambas puntúan. Un juicio sobre la *gente como objeto de afecto* ("the people are so warm") es simpática; un juicio sobre la *gente como productora de cultura* ("Mexican artisans are incredibly skilled") tiende a estética/funcional según el objeto.
3. **Funcional vs saliencia de violencia (gestión vs hecho).** La crítica a la gestión de seguridad = funcional; la mención del hecho violento = saliencia (Rúbrica 4, binaria 0/1, agregada como proporción diaria). Un tuit puede tener saliencia de violencia = 1 y

funcional = 1 simultáneamente (reporta el tiroteo Y culpa a las autoridades). Las cuatro variables se codifican para todo tuit: tres ordinales 0-5 + una binaria 0/1.

4. **Funcional vs simpática (miedo institucional vs miedo afectivo).** "The security was incompetent" = funcional negativo. "I'm scared to be here" = simpática negativa (miedo afectivo difuso). "The police failed and now I'm terrified" = ambas.
5. **Prioridad de asignación intra-dimensión:** dentro de cada rúbrica, si el tuit contiene varios enunciados de la misma dimensión con valencias distintas, aplicar best-fit por **balance dominante** (no promedio aritmético): el nivel que refleja el peso comunicativo principal del tuit. Si están genuinamente equilibrados → 3.
6. **Regla de exhaustividad (collectively exhaustive):** todo tuit recibe un valor 0-5 en las tres variables. Ningún tuit queda sin codificar; la ausencia se codifica como 0, garantizando exhaustividad.
7. **Regla geográfica transversal (todas las dimensiones):** las cuatro variables miden percepciones **sobre México** exclusivamente. Contenido afectivo, cultural, funcional o de violencia referido a otros países (incluidas las co-sedes EE.UU. y Canadá) o genérico sin anclaje en México → 0 en la dimensión correspondiente. "US stadiums are way better organized" → funcional 0 (no evalúa a México; si el tuit compara explícitamente y emite juicio sobre México — "US stadiums are way better organized than Mexico's" — entonces sí codifica el juicio sobre México: funcional 2). Ante ambigüedad de referente en un corpus ya filtrado por México, aplicar el contexto razonable del hilo. **Deixis:** expresiones como "this country", "here", "aquí", "este lugar" se resuelven hacia México cuando el contexto del tuit o del hilo lo indica (el emisor está en México, responde a contenido sobre México, o usa hashtags/geolocalización de sedes mexicanas); si el referente deíctico no puede resolverse hacia México → 0 en la dimensión.

(e) Protocolo de fiabilidad recomendado (reliability protocol)

1. Doble codificación de submuestra. Codificar por duplicado (dos codificadores humanos independientes, o humano + LLM) una submuestra aleatoria — convención habitual: 10-20% del corpus, con un mínimo absoluto de ~50-100 unidades por celda de interés para estabilidad del estimador. Extraer la submuestra de reliability *antes* de codificar el grueso, y fijar el umbral en el protocolo antes de mirar los resultados.

2. Estadístico apropiado: Krippendorff's alpha con métrica ordinal. Es el estadístico correcto porque (i) las variables son ordinales, (ii) admite cualquier número de codificadores, (iii) maneja datos faltantes, y (iv) usa la métrica de diferencia ordinal que penaliza más los desacuerdos lejanos que los cercanos. **Crítico:** usar la métrica **ordinal**, no la nominal. La métrica nominal trata un desacuerdo 4↔5 igual que 1↔5, fabricando desacuerdo inexistente; en un mismo set de 20 unidades calificadas 1-5 por dos codificadores la métrica nominal puede dar .451 y la ordinal .887 — veredictos opuestos con los mismos números. Alternativa válida

con **exactamente dos codificadores** y sin datos faltantes: kappa ponderado de Cohen (weighted kappa, Cohen 1968) con pesos cuadráticos, que también da crédito parcial a near-misses ordinales.

3. Umbrales (Krippendorff 2004, *Content Analysis*, p. 241, verbatim): "*it is customary to require $\alpha \geq .800$. Where tentative conclusions are still acceptable, $\alpha \geq .667$ is the lowest conceivable limit.*" Es decir: $\alpha \geq .800$ = fiable para conclusiones firmes; $.667 \leq \alpha < .800$ = solo conclusiones tentativas; $\alpha < .667$ = descartar / rediseñar codebook. Reportar el punto estimado **con intervalo de confianza bootstrap**, porque en submuestras pequeñas un punto estimado apenas por encima de .800 no garantiza que el valor poblacional lo supere.

4. Doble cálculo por el problema del nivel 0. Calcular α (i) sobre la escala completa 0-5, (ii) sobre la subescala condicional 1-5 (excluyendo pares donde ambos codificaron 0), y (iii) un alpha/kappa nominal sobre la dummy de presencia (0 vs ≥ 1). Esto verifica que el acuerdo no dependa solo de la prevalencia de ceros. **Para la Rúbrica 4 (saliencia de violencia, binaria)** usar directamente alpha/kappa **nominal** (no hay orden que preservar entre dos categorías); vigilar el efecto de prevalencia: si la gran mayoría de tuits es 0, kappa puede deprimirse pese a un acuerdo bruto alto (paradoja de kappa) — reportar también el porcentaje de acuerdo observado y, opcionalmente, PABAK como sensibilidad.

5. Ciclo de calibración iterativo (standardization). Antes del coding formal: pilotar ~50-70 tuits, discutir desacuerdos abiertamente, refinar descriptores y añadir reglas empíricas y palabras clave al codebook; luego checkpoints periódicos (p. ej. cada 10-20% del corpus) recalculando IRR, como en la práctica estándar de content analysis. Documentar cada revisión del codebook.

6. Si se usa un LLM como codificador. Es aceptable y crecientemente estándar (LLM-Assisted Content Analysis, LACA; Chew et al. 2023, arXiv:2306.14924), tratando al modelo como un codificador más:

- **El prompt = la rúbrica** (este codebook), pero **reescrita para comprensión de máquina** (Dunivin 2024/2025, *Scaling hermeneutics*, EPJ Data Science): reemplazar convenciones inferenciales de codificadores humanos por criterios explícitos de desambiguación, incluir ejemplos negativos estrictos, y pedir al modelo que **articule su razonamiento antes** de emitir la etiqueta. El acuerdo mejora con rationale: GPT-4 zero-shot logra equivalencia humana con $\mu(\kappa) = 0.68$ al dar razonamiento vs. $\max(\kappa) = 0.55$ sin él; con los mismos prompts, GPT-3.5 promedia solo $\kappa = 0.34$ (por lo que el modelo importa).
- **Validación obligatoria contra humanos:** calcular IRR humano-LLM con las mismas métricas y comparar con el IRR humano-humano; idealmente equivalentes. Si el LLM es inferior en alguna categoría, re-ingeniar el prompt o codificar esa categoría a mano.
- **Reproducibilidad:** temperatura baja (0-0.3) para clasificación; para casos límite, generar múltiples corridas y tomar el voto mayoritario (consistency score = proporción de

corridas que coinciden con la moda; los ítems con consistencia < 1.0 marcan edge cases de menor exactitud — la exactitud es ~ 19 puntos porcentuales mayor en ítems con consistencia 1.0). Documentar versión del modelo, prompt exacto y fecha (las APIs cambian y afectan la replicabilidad).

- **No confiar en determinismo perfecto a $T=0$:** incluso a temperatura 0 los modelos hospedados muestran variación run-to-run; reportarla en la submuestra de validación.

7. Reportaje completo (full reportage). En la tesis documentar: tamaño y método de muestreo de la submuestra de reliability, número y formación de codificadores, método de resolución de desacuerdos, la métrica y su función de diferencia, el α con IC, y las decisiones de codebook. Esto es lo que un jurado espera y lo que la literatura de content analysis (Neuendorf, *The Content Analysis Guidebook*, 2ª ed.) considera "high bar".

Recomendaciones

Etapas 1 — Antes de codificar (fijar el diseño). (a) Adoptar la escala híbrida 0-5 descrita, y **preregistrar** en la metodología las tres representaciones analíticas: escala 0-5 completa, valencia condicional 1-5, y dummy de presencia. (b) Reescribir este codebook en dos versiones: una para codificadores humanos y otra optimizada para el LLM (criterios explícitos + ejemplos negativos + razonamiento previo). (c) Fijar el umbral de fiabilidad (recomendado: α ordinal $\geq .80$ para conclusiones firmes; aceptar .667-.80 solo como tentativo y declararlo).

Etapas 2 — Piloto y calibración. Codificar 50-70 tuits por duplicado, calcular α ordinal preliminar, discutir desacuerdos, refinar descriptores/reglas de frontera. Repetir hasta superar el umbral en el piloto. **Benchmark que cambia la decisión:** si $\alpha < .667$ en el piloto, NO avanzar al corpus completo; rediseñar los descriptores de los pares adyacentes con más desacuerdo (típicamente 2-3 y 3-4, las fronteras neutral/valencia).

Etapas 3 — Codificación a escala. Codificar el corpus con el codificador elegido (humano o LLM validado). Mantener doble codificación en 10-20% con checkpoints periódicos.

Benchmark: si el α humano-LLM cae por debajo del α humano-humano en más de $\sim .05$ -.10, re-ingeniar el prompt de las categorías afectadas antes de continuar.

Etapas 4 — Análisis e informe. Reportar por día: mediana + distribución porcentual de cada dimensión (en las tres representaciones), la saliencia dimensional (proporción ≥ 1), y la saliencia de violencia. Cruzar funcional-negativo con saliencia de violencia para el argumento central de la tesis (percepciones de violencia $\leftrightarrow$ imagen país). Reportar α con IC bootstrap para cada dimensión.

Umbrales que cambian las conclusiones: (i) $\alpha \geq .80 \rightarrow$ conclusiones firmes; (ii) .667-.80 $\rightarrow$ etiquetar todas las inferencias como "tentativas"; (iii) $< .667 \rightarrow$ los datos de esa dimensión no sustentan conclusiones y deben rediseñarse. (iv) Si la proporción de ceros supera ~ 70 -80% en

una dimensión, priorizar el análisis condicional 1-5 y la dummy de presencia sobre la mediana cruda.

Advertencias

- **El nivel 0 híbrido es el punto metodológicamente más vulnerable.** La solución propuesta lo conserva por decisión de diseño, pero un jurado exigente puede objetar que mezcla activación y valencia; la defensa depende de reportar consistentemente las representaciones separadas (presencia + valencia condicional). No se puede eliminar por completo la objeción manteniendo el formato 0-5 solicitado.
- **Los indicadores formativos verbatim provienen mayoritariamente del instrumento del estudio de EE.UU./comportamiento de viaje de Buhmann & Ingenhoff (2015)** (muestra de estudiantes suizos, $n \approx 208$); el segundo estudio (Buhmann 2016) reporta pesos distintos (p. ej. el factor funcional dominante cambia de "competencias del liderazgo político" a "calidad de productos y servicios"), lo que confirma que los pesos son dependientes de la muestra. Para tuits sobre un Mundial, los subtemas dominantes serán probablemente organización, seguridad-gestión e infraestructura (funcional) y gastronomía/tradiciones (estética), no necesariamente los que Buhmann halló en encuestas.
- **La dimensión normativa del modelo 4D queda fuera** por decisión de diseño; conviene declararlo explícitamente en la tesis, porque juicios sobre derechos humanos, desapariciones o corrupción (muy presentes en el discurso Mundial 2026-México) pertenecen conceptualmente a la dimensión normativa y podrían ser mal forzados hacia la funcional si no se advierte. Considerar una regla de exclusión explícita o una nota de que el contenido normativo puro se registra como 0 en las tres dimensiones codificadas.
- **La fiabilidad ordinal puede inflarse por prevalencia de ceros;** de ahí la recomendación del doble cálculo. Un α alto sobre 0-5 con 80% de ceros puede ocultar bajo acuerdo en la valencia 1-5, que es lo sustantivo.
- **La reproducibilidad del LLM no está garantizada** ni siquiera a temperatura 0; las versiones de API cambian sin aviso. Documentar todo y, para la tesis, conservar los outputs crudos y el prompt exacto.
- **Los ejemplos de tuits son inventados** (realistas, bilingües) para ilustrar niveles; no son datos empíricos.
- **Precaución con el uso de la mediana en escala 0-5 mezclada:** al ser 0 una categoría cualitativamente distinta, una mediana de 0 significa "la mayoría de tuits no tocan la dimensión", no "valencia mínima". Interpretar siempre la mediana junto a la distribución porcentual y a la saliencia dimensional para evitar lecturas engañosas.